

Разработка потокового ETL-конвейера для анализа пользовательской активности интернет-магазина в реальном времени

Описание

Интернет-магазин генерирует непрерывный поток событий о поведении пользователей: просмотры карточек товаров, добавления в корзину, оформление заказов, а также технические события (запросы к серверу, коды ответов) из логов Nginx. В качестве источника подготовленных событий используется отдельно заhostенная база данных PostgreSQL (внешний сервер), из которой данные забираются через API — в том числе через Yandex DataLens как промежуточный слой доступа к данным. Цель проекта — разработать конвейер данных на языке Python, который принимает эти события в реальном времени через Apache Kafka, обрабатывает их с помощью потоковых вычислений и формирует аналитические витрины, отражающие состояние магазина «здесь и сейчас». Обработанные данные обязательно сохраняются в локальную базу PostgreSQL, которая выступает основным хранилищем готовых витрин для отчётности.

Конвейер должен решать типовые бизнес-задачи e-commerce-аналитики:

- расчёт конверсии воронки «просмотр → корзина → заказ» в реальном времени;
- детектирование брошенных корзин (добавление товара без последующего заказа в течение заданного интервала);
- формирование рейтинга популярных товаров на скользящем временном окне;
- выявление аномалий трафика по логам Nginx (всплески ошибок 4xx/5xx, резкие скачки нагрузки).

Помимо потоковой части, конвейер включает пакетные (batch) задачи, оркестрируемые Apache Airflow: регулярные агрегации, проверки качества данных и формирование сводных отчётов, — что позволяет продемонстрировать сочетание потоковой и пакетной обработки данных в рамках одного проекта.

Обоснование выбора темы

Тема выбрана с учётом имеющегося опыта: уверенное владение Docker и Nginx, а также опыт работы с брокером сообщений ArtemisMQ, что облегчает освоение Apache Kafka (схожие концепции — продюсеры, консьюмеры, топики вместо очередей). Область e-commerce даёт понятный набор бизнес-метрик и мотивированную актуальность, а потоковая обработка соответствует современным требованиям к инжинирингу данных и демонстрирует более широкий набор компетенций, чем классический батчевый ETL. Вся реализация выполняется на языке Python в соответствии с требованиями преподавателя; использование PostgreSQL как на стороне источника (внешняя БД с подготовленными событиями), так и на стороне хранилища обработанных данных (локальная БД) закрывает обязательное требование к использованию реляционной СУБД в проекте.

Технологический стек

Компонент	Технология	Назначение
Язык программирования	Python 3.10+	Основной язык реализации всех модулей конвейера
Источники данных	Логи Nginx, события фронтенда (JSON), внешняя БД PostgreSQL с подготовленными событиями	Клики, запросы, действия пользователя; заранее подготовленные события забираются через API / Yandex DataLens
Приём событий	Apache Kafka	Приём и буферизация потока событий
Потоковая обработка	PySpark Structured Streaming	Оконные агрегации, расчёт метрик в реальном времени
Оркестрация	Apache Airflow	Пакетные задачи: агрегации, контроль качества, отчёты
Хранилище (raw)	MinIO (S3-совместимое)	Хранение сырых событий (Data Lake)
Хранилище обработанных данных	PostgreSQL (локально)	Основное хранилище готовых витрин и обработанных данных
Хранилище (DWH, real-time)	ClickHouse	Быстрые аналитические витрины для потоковых метрик
Контроль качества	Great Expectations	Валидация схем событий, поиск пропусков и дублей
Визуализация / мониторинг	Grafana	Дашборд метрик в реальном времени, мониторинг пайплайна
Инфраструктура	Docker Compose	Воспроизводимое развёртывание всего стека

Примечание: тема сформулирована свободно на основе примерного перечня тем курсового проекта (темы 1, 6 и 12 методических указаний) и подлежит согласованию с руководителем курсового проекта.